Introdução à análise exploratória de dados

Wagner H. Bonat Elias T. Krainski Fernando P. Mayer

Universidade Federal do Paraná Departamento de Estatística Laboratório de Estatística e Geoinformação







Sumário

- Ideias gerais
- Análise exploratória de dados
 - Organização dos dados.
 - Tabelas de frequência.
 - Representação gráfica.
- Exercícios recomendados

O que é estatística?

- Estatística é um conjunto de técnicas para, sistematicamente:
 - Planejar a coleta de dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento;
 - Descrever, analisar e interpretar dados;
 - Extrair informações para subsidiar decisões;
 - Avaliar evidências empíricas sob hipóteses de interesse.
- Exemplos de aplicações:
 - Opinião da população brasileira sobre o novo governo.
 - Avaliar a efetividade de uma nova droga para a cura do câncer.
 - Entender os hábitos de compra dos clientes de uma loja virtual.
 - Recomendação personalizada de produtos.
 - Comparar a produtividade da soja sob diferentes formas de cultivo, adubação, etc.

População e amostra

- Conceitos fundamentais
 - População: Conjunto de todos os elementos sob investigação.
 - Amostra: Subconjunto da população.
 - Variável de interesse: característica a ser observada em cada indivíduo da amostra.


Exemplos em detalhes

- Opinião da população brasileira sobre o novo governo.
 - População: Todos os habitantes do Brasil? outras opções?
 - Amostra: Algum subconjunto da população. Qualquer um será? Como selecionar?
 - Variável de interesse: Opinião sobre o novo governo. Como medir isso? Gosta? sim ou não.
- Avaliar a efetividade de uma nova droga para a cura do câncer.
 - **População**: Todos os seres humanos? Apenas os já doentes? Como levar em conta questões de raça, culturas, etc . . .
 - Amostra: E agora?
 - Variável de interesse: Curou ou não curou? Será que isso é possível?
- Entender os hábitos de compra dos clientes de uma loja virtual.
 - População: Todos os clientes da loja virtual.
 - Amostra: Preciso de amostra?
 - Variável de interesse: E agora? Como caracterizar hábito de compra?

Divisões básicas da estatística

- Divisões essenciais em Estatística e seus principais objetivos.
 - Estatística descritiva ou exploratória:
 - Consistência dos dados e interpretações iniciais.
 - Visualização dos dados e relações entre variáveis.
 - Probabilidade:
 - Fornece ferramentas para lidar/quantificar incerteza.
 - Inferência estatística:
 - Estimação de quantidades desconhecidas.
 - Formular e testar hipóteses.
 - Extrapolar para a população resultados obtidos na amostra.

Ideia final



Etapas da análise estatística

- Definir a população de interesse.
 - População factível.
- Estabelecer os objetivos (questões) de pesquisa.
 - Definir critérios objetivos sobre quais dados coletar.
 - Postular a análise estatística a ser utilizada.
- Definir o método para coletar as amostras.
 - Fonte de dados secundários (IBGE, IPEA, etc);
 - Banco de dados da empresa;
 - Pesquisas amostrais;
 - Experimentos em laboratórios, etc.
- Análise dos dados.
 - Análise descritiva e exploratória (o que aconteceu na amostra?).
 - Análise inferencial (o que acontece na população?).

Planejamento da coleta de dados

- Definição do experimento
 - Variáveis respostas/interesse.
 - Variáveis de controle (o que afeta a resposta?).
 - Desenho do experimento e randomização.

Planejamento da coleta de dados


- Definição do experimento
 - Variáveis respostas/interesse.
 - Variáveis de controle (o que afeta a resposta?).
 - Desenho do experimento e randomização.
- Coleta de dados por amostragem
 - Definição da população e característica de interesse.
 - Definição do plano amostral:
 - Aleatória simples (com ou sem reposição) ou sistemática;
 - Estratificada, por estratos da população (segundo uma característica);
 - Conglomerados, por grupos de indivíduos da população (subpopulações);
 - Amostragem complexa (combina anteriores).

Planejamento da coleta de dados

- Definição do experimento
 - Variáveis respostas/interesse.
 - Variáveis de controle (o que afeta a resposta?).
 - Desenho do experimento e randomização.
- Coleta de dados por amostragem
 - Definição da população e característica de interesse.
 - Definição do plano amostral:
 - Aleatória simples (com ou sem reposição) ou sistemática;
 - Estratificada, por estratos da população (segundo uma característica);
 - Conglomerados, por grupos de indivíduos da população (subpopulações);
 - Amostragem complexa (combina anteriores).
- Coleta de dados observacionais. Exemplos:
 - Presença de seres vivos num ambiente;
 - Fenômenos climáticos; Fluxo de usuários em um website.

LEG/DEST/UFPR Análise exploratória 9 / 37

Resumo: Objetivos e etapas da análise estatística



** A forma de coleta dos dados é um tópico em si. No entanto neste curso básico ela será discutida de forma superficial dentro do tópico de análise exploratória.**

LEG/DEST/UFPR Análise exploratória 10 / 37

Sumário

- Ideias gerais
- 2 Análise exploratória de dados
 - Organização dos dados.
 - Tabelas de frequência.
 - Representação gráfica.
- Exercícios recomendados

Exemplo

Pesquisa foi realizada com alunos. Variáveis:

- Id: identificação do aluno; Turma: A ou B;
- Sexo: feminino (F) ou masculino (M);
- Idade: em anos; Alt: altura em metros;
- Peso: em quilogramas; Filhos: nº de filhos na família;
- Fuma: hábito de fumar: sim (S) ou não (N);
- Toler: tolerância ao cigarro: (I) indiferente; (P) incomoda pouco; (M) incomoda muito;
- Exerc.: horas de atividade física, por semana;
- Cine: nº. de vezes que vai ao cinema por semana;
- **OpCine**: opinião a respeito das salas de cinema na cidade: (B) regular a boa; (M) muito boa;
- TV: horas gastas assistindo TV, por semana;
- **OpTV**: opinião a respeito da qualidade da programação na TV: (R) ruim; (M) média; (B) boa; (N) não sabe.

Organização dos dados

- A partir de um conjunto de dados coletado, a questão é:
 - Como extrair informações a respeito de uma ou mais características de interesse?
- Basicamente temos duas opções:
 - Tabelas de freguência;
 - Gráficos.
- O importante é levar em consideração a natureza dos dados.

Organização de Dados


- Uma típica tabela de dados brutos contém:
 - Variáveis (características, medições, etc) nas colunas.
 - Sujeito (indivíduo, objetos, etc) nas linhas.

```
Id Turma Sexo Idade Alt Peso Filhos Fuma Toler Exerc Cine OpCine TV OpTV
                17 1.60 60.5
                                     NAO
                                                                16
                18 1.69 55.0
                                     NAO
3
                18 1.85 72.8
                                  2 NAO
                                                               M 15
4
                25 1.85 80.9
                             2 NAO
                                                               B 20
5
                19 1.58 55.0
                                     NAO
                19 1.76 60.0
                                     NAO
```

- Tipos de variáveis:
 - Qualitativa nominal: Turma, Sexo, Fuma.
 - Qualitativa ordinal: Toler, OpCine, OpTV.
 - Quantitativa discreta: Idade, Filhos, Exerc, Cine, TV.
 - Quantitativa contínua: Alt. Peso.

LEG/DEST/UFPR Análise exploratória 14 / 37

Tipos de variáveis



Tabelas de frequência

- A tabela de dados brutos pode ser muito longa, portanto será difícil extrair alguma informação.
- As tabelas de frequência ajudam a resumir a informação da variável de interesse.
- Vamos usar 3 tipos de frequência:
 - Frequência **absoluta**: contagem de cada valor observado. Representado por n_i o número de indivíduos com a característica i.
 - Frequência **relativa**: número de indivíduos com a característica *i* dividido pelo total de indivíduos n, ou seja $f_i = \frac{n_i}{n}$.
 - Frequência acumulada: frequência (absoluta ou relativa) acumulada até um certo valor, obtida pela soma das frequências de todos os valores da variável, menores ou iguais ao valor considerado.

Tabela de frequência - qualitativa nominal

Considerando a variável Sexo

	nį	fi
F	37	0.74
M	13	0.26
Sum	50	1.00

• Neste caso não faz sentido usar frequência acumulada.

Tabela de frequência - qualitativa ordinal

Considerando a variável OpTV

	ni	f _i	f _{ac}
R	39	0.78	0.78
M	1	0.02	0.80
В	3	0.06	0.86
N	7	0.14	1.00
Sum	50	1.00	

LEG/DEST/UFPR Análise exploratória 18 / 37

Tabela de frequência - quantitativa discreta

Considerando a variável Idade

	nį	fi	f_{ac}
17	9	0.18	0.18
18	22	0.44	0.62
19	7	0.14	0.76
20	4	0.08	0.84
21	3	0.06	0.90
22	0	0.00	0.90
23	2	0.04	0.94
24	1	0.02	0.96
25	2	0.04	1.00
Sum	50	1.00	

LEG/DEST/UFPR Análise exploratória 19 / 37

Tabela de frequência - quantitativa contínua

- No caso de quantitativas contínuas não faz sentido contar cada valor pois podem existir muitos (potencialmente infinito).
- A solução é criar classes ou faixas de valores, e contar o número de ocorrências dentro destas classes.
- Para definir as classes:
 - Defina a amplitude da classe, de maneira que se obtenham de 5 a 8 classes (de mesma amplitude).
 - Identifique os valores máximo e mínimo da variável e construa as classes de maneira que inclua todos os valores.
- As classes de valores podem seguir um dos formatos:

Classe	Notação	Denominação	Resultado
[a, b) (a, b]		Fechado em a, aberto em b Aberto em a, fechado em b	,

LEG/DEST/UFPR Análise exploratória 20 / 37

Tabela de frequência - quantitativa contínua

- Considerando a variável Peso
 - Foram construídas 6 classes de amplitude 10.
 - As classes são do tipo [a, b) ou $a \vdash b$.

	nį	fi	f_{ac}
[40, 50)	8	0.16	0.16
[50, 60)	22	0.44	0.60
[60, 70)	8	0.16	0.76
[70, 80)	6	0.12	0.88
[80, 90)	5	0.10	0.98
[90, 100)	1	0.02	1.00
Sum	50	1.00	

Tabela de frequência - quantitativa discreta (muitos valores)

- Considerando a variável TV.
- Apesar de ser discreta, o número de valores únicos é muito grande e não seria útil contar as frequências de cada valor.
- Neste caso, utiliza-se o mesmo procedimento usado para quantitativas contínuas
 - Foram construídas 6 classes de amplitude 6¹.

	ni	fi	f _{ac}
[0, 6)	14	0.28	0.28
[6, 12)	17	0.34	0.62
[12, 18)	11	0.22	0.84
[18, 24)	4	0.08	0.92
[24, 30)	3	0.06	0.98
[30, 36)	1	0.02	1.00
Sum	50	1.00	

¹Obs.: no livro a tabela tem 5 classes, pois a última tem comprimento 12


LEG/DEST/UFPR Análise exploratória 22 /

Representação gráfica

- Podemos visualizar as tabelas através de gráficos.
- Existe um tipo de gráfico adequado para cada tipo de variável.
- Cuidado deve ser tomado com representações visuais pois um gráfico desproporcional pode gerar interpretações distorcidas.
- As principais representações gráficas são:
 - Diagrama circular (setores ou "pizza");
 - Gráfico de barras;
 - Histogramas;
 - Boxplots.

Diagrama circular


• Adequado para variáveis qualitativas nominal e ordinal.



• O uso deste tipo de gráfico deve ser evitado, pois pode ser de difícil interpretação.

Gráfico de barras


- Adequado para variáveis qualitativas nominal/ordinal e quantitativa discreta (poucos valores distintos).
- Podem ser usadas as frequências absolutas ou relativas.




LEG/DEST/UFPR Análise exploratória 25 / 37

Histograma

• Adequado para quantitativa contínua.



Tipos de assimetria



LEG/DEST/UFPR Análise exploratória


Mediana e quartis

- Mediana: valor da variável que divide o conjunto de dados ordenado em dois subgrupos de mesmo tamanho.
- Quartis: valores da variável que divide o conjunto de dados ordenados em quatro subgrupos de mesmo tamanho.
- Posição dos quartis:
 - $Q_1 = 0.25 \cdot (N+1)$ e arredonde.
 - $Q_2=$ média dos valores nas posições (N/2) e (N/2)+1 se N par e $Q_2=(N+1)/2$ se N ímpar.
 - $Q_3 = 0.75 \cdot (N+1)$ e arredonde.
- Exemplo: Conside o conjunto de dados: 8.43(1), 8.65(2), 9.96(3), 10.91(6), 10.46(4) e 10.83(5).
 - $Q_1 = 0.25 \cdot 7 = 1.75 \approx 2$, ou seja 8.65.
 - $Q_2 = \text{m\'edia dos valores nas posiç\~oes 3 e 4, ou seja, } (9.96 + 10.46)/2 = 10.21.$
 - $Q_3 = 0.75 \cdot 7 = 5.25 \approx 5$, ou seja, 10.83.

LEG/DEST/UFPR Análise exploratória 28 / 37

Boxplot


- Adequado para quantitativa contínua.
- Pode ser usado também para quantitative discreta com muitos valores.



LEG/DEST/UFPR Análise exploratória 29 /

Boxplots


• Excelente para explorar relações entre qualitativas e contínuas.



LEG/DEST/UFPR Análise exploratória 30

Diagrama de dispersão


• Adequado para explorar a relação entre variáveis quantitativas.



LEG/DEST/UFPR Análise exploratória 31

Diagrama de dispersão


• Exemplos de comportamentos do diagrama de dispersão.



LEG/DEST/UFPR Análise exploratória 32 / 37

Diagrama de dispersão


Formas não lineares.



LEG/DEST/UFPR Análise exploratória 33 / 37

Gráfico de mosaico

• Adequado para explorar a relação entre variáveis qualitativas (nominais ou ordinais).



Sexo

Resumo

- Qualitativa nominal ou ordinal
 - Gráfico de setores.
 - Gráfico de barras.
- Quantitativa discreta
 - Gráfico de barras (poucos valores).
 - Histograma ou boxplot (muitos valores).
- Quantitativas contínuas
 - Histograma ou boxplot.
- Explorando relações:
 - Quantivativa vs Quantitativa: Diagrama de dispersão.
 - Qualitativa vs Quantitativa: Boxplots.
 - Qualitativa vs Qualitativa: Gráfico de mosaico.

Sumário

- Ideias gerais
- Análise exploratória de dados
 - Organização dos dados.
 - Tabelas de frequência.
 - Representação gráfica.
- Sercícios recomendados

Exercícios recomendados

- Seção 1.1: Ex. 1, 2 e 3.
- Seção 1.2: Ex. 1 e 4.
- Seção 1.4: Ex. 1, 3, 5 (troque diagrama circular por gráficos de barras), 8, 9, 12, 18 e 20.